

Profilage — dataset decrochage_etudiants_complet_V5.csv

5240 lignes · 33 colonnes · 40 lignes en double · utf-8-sig

☾ Sombre

Comment lire ce rapport

type_reel vs type_semantique

Le premier est ce que pandas infère spontanément, le second ce que la colonne *représente*. Leur écart trahit une valeur textuelle intrusive dans une colonne de nombres.

n_distinct vs n_distinct_normalise

Le nombre de modalités avant et après uniformisation de l'écriture (casse, accents, espaces). Un écart signale des modalités qui n'en sont pas.

non_conforme_%

La part des valeurs écrites hors de la forme canonique de leur type. **Aucune n'est fausse** : la mesure porte sur l'hétérogénéité d'écriture, celle qui empêche de compter ou d'agréger.

min / max

Les bornes, lues sur la **grandeur** et non sur l'écriture :
9,5 ne dépasse pas 12.0 km. Colonnes ordonnables
seulement — nombres et dates.

motif d'écriture

La forme généralisée des valeurs $\{d_4\} - \{d_2\}$. Renseigné pour les seules colonnes restées en texte alors qu'elles portent un nombre, une date ou un identifiant : ailleurs il ne dirait que l'ordre de grandeur ou la longueur d'un libellé.

n_motifs → motifs

Le nombre de motifs est **cliquable** : il ouvre leur inventaire, avec effectif, part et **exemple réel**. À lire avant de conclure sur `couverture_motif_%` — une couverture de 33 % laisse croire à deux tiers de valeurs mal écrites, alors que les deux premiers motifs peuvent n'être que le même nombre à un chiffre près (5.5 et 18.8).

exemples → modalités

Une cellule d'exemples **cliquable** ouvre l'inventaire exhaustif des modalités de la colonne : effectifs, part, et écritures brutes avec leurs espaces de bord rendus visibles.

Un tiret n'est pas un zéro

– se lit « sans objet pour ce type de colonne », jamais « mesure nulle ». Un zéro, lui, est écrit 0.

Fichier

FICHER

dataset decrochage_etudiants_complet_V5.csv

ENCODAGE

utf-8-sig (avec BOM)

DÉLIMITEUR

« , »

LIGNES

5 240

COLONNES

33

LIGNES EN DOUBLE

40

TAILLE

887.4 Kio

Colonnes

Filtrer par nom de colonne...

Tout type réel ▼

Tout type sémantique

```
n_distinct = 1
```

non conformes

manquants

33 / 33 colonnes

Réinitialiser

colonne ↴	type_reel ↴	type_semantique ↴	motif_dominant ↴	couverture_motif_% ↴	n_motifs ↴	n_distinct ↴	n_distinct_normalise ↴	min ↴	max ↴	null_% ↴	non_conforme_% ↴	exemples ↴	remarques ↴
student_id	str	identifiant	\w{3}\~\d{5}	100.0	1	5200	5200	—	—	0	0	ETU-03041 ETU-03916 E...	
annee_universitaire	str	constant	—	—	—	1	1	—	—	0	0	2024-2025 1	
filiere	str	catégoriel	—	—	—	31	8	—	—	0	43.03	droit Lettres Lettres 8	
age	int64	entier	—	—	—	11	11	17	27	0	0	22 19 17 11	
sexe	str	catégoriel	—	—	—	11	8	—	—	0	37.23	NB femme h 8	
bac_type	str	catégoriel	—	—	—	12	7	—	—	0	37.58	TECHNO general GEN 7	
mention_bac	str	catégoriel	—	—	—	11	8	—	—	4.05	25.86	AB passable ab 8	
etablissement_origine	str	catégoriel	—	—	—	4	4	—	—	4.98	0	lycee_public lycee_privé c... 4	
boursier	str	booléen	—	—	—	8	6	—	—	0	24.56	Oui N Non 6	
distance_domicile_km	str	décimal	\d{2}\. \d	33.6	8	1233	1233	0.0	138.0	5.99	33.66	2,2 18.8 42,8	unité(s) collée(s) : « km » ; virg...
heures_travail_remunere_sem	float64	décimal	—	—	—	27	27	0.0	28.0	11.95	0	0.0 9.0 15.0	
taux_presence_pct	str	décimal	\d{2}\. \d	59.7	3	1343	1343	34.8	99.9	0	40.27	86,3 77.5% 74,6	unité(s) collée(s) : « % » ; virgu...
connexions_lms_30j	float64	entier	—	—	—	78	78	0	81	4.01	0	33 45 37	
heures_lms_total	float64	décimal	—	—	—	1044	1044	0.0	170.5	0	0	35.4 56.7 77.1	
ressources_consultees	int64	entier	—	—	—	178	178	0	222	0	0	73 114 77	
retards_rendus	int64	entier	—	—	—	11	11	0	10	0	0	2 3 4 11	
nb_devoirs_total	int64	entier	—	—	—	6	6	8	13	0	0	12 13 9 6	
nb_devoirs_rendus	int64	entier	—	—	—	14	14	0	13	0	0	11 10 6 14	
messages_forum	int64	entier	—	—	—	17	17	0	18	0	0	4 7 0 17	
moyenne_partiels_s1	str	décimal	\d{2}\. \d{2}	41.1	8	2039	2039	0.0	20.0	3.0	30.55	10,17 10.17 10.75	virgule décimale
nb_ue_total	int64	entier	—	—	—	3	3	5	7	0	0	6 5 7 3	
nb_ue_validees_s1	int64	entier	—	—	—	8	8	0	7	0	0	5 4 2 8	
motivation	float64	entier	—	—	—	5	5	1	5	5.0	0	3 2 4 5	

colonne ↕	type_reel ↕	type_semantique ↕	motif_dominant ↕	couverture_motif_% ↕	n_motifs ↕	n_distinct ↕	n_distinct_normalise ↕	min ↕	max ↕	null_% ↕	non_conforme_% ↕	exemples ↕	remarques ↕
satisfaction	float64	entier	—	—	—	5	5	1	5	8.0	0	3 5 2 5	
sentiment_appartenance	float64	entier	—	—	—	5	5	1	5	6.98	0	3 1 4 5	
groupe_td	str	catégoriel	—	—	—	8	8	—	—	0	0	D C A 8	
couleur_carte_etudiante	str	catégoriel	—	—	—	5	5	—	—	0	0	jaune bleu gris 5	
jour_inscription	str	catégoriel	—	—	—	5	5	—	—	0	0	mercredi vendredi jeudi 5	
id_dossier	int64	identifiant	—	—	—	5200	5200	—	—	0	0	265469 800111 982786	
date_inscription	str	date	\d{4}\-\d{2}\-\d{2}	33.5	3	60	60	2024-09-02	2024-09-27	0	66.45	04 Sep 2024 2024-09-27 ...	3 formats mêlés : %Y-%m-%d,...
moyenne_finale	float64	decimal	—	—	—	1804	1804	0.22	19.9	0	0	15.06 15.61 14.85	
champs	float64	catégoriel	—	—	—	2	2	—	—	0	0	0 1 5	